

# Conceptos para la compresión con pérdida

Rafael Molina

Depto Ciencias de la Computación  
e Inteligencia Artificial  
Universidad de Granada

Conceptos para codificación con  
pérdida

# Contenidos

- I. Objetivos del tema
- II. Introducción
- III. Criterios de distorsión
- IV. Teoría de la información revisitada
- V. Teoría Razón/Distorsión (Rate/Distortion)
- VI. Modelos para la fuente
- VII. Bibliografía

# I. Objetivos del tema

En la compresión sin pérdida la preocupación estaba en el factor de compresión o equivalentemente la **tasa** (rate) o número de bits por muestra, ahora en la compresión con pérdida hemos de mirar también a la **distorsión** que la pérdida de información produce.

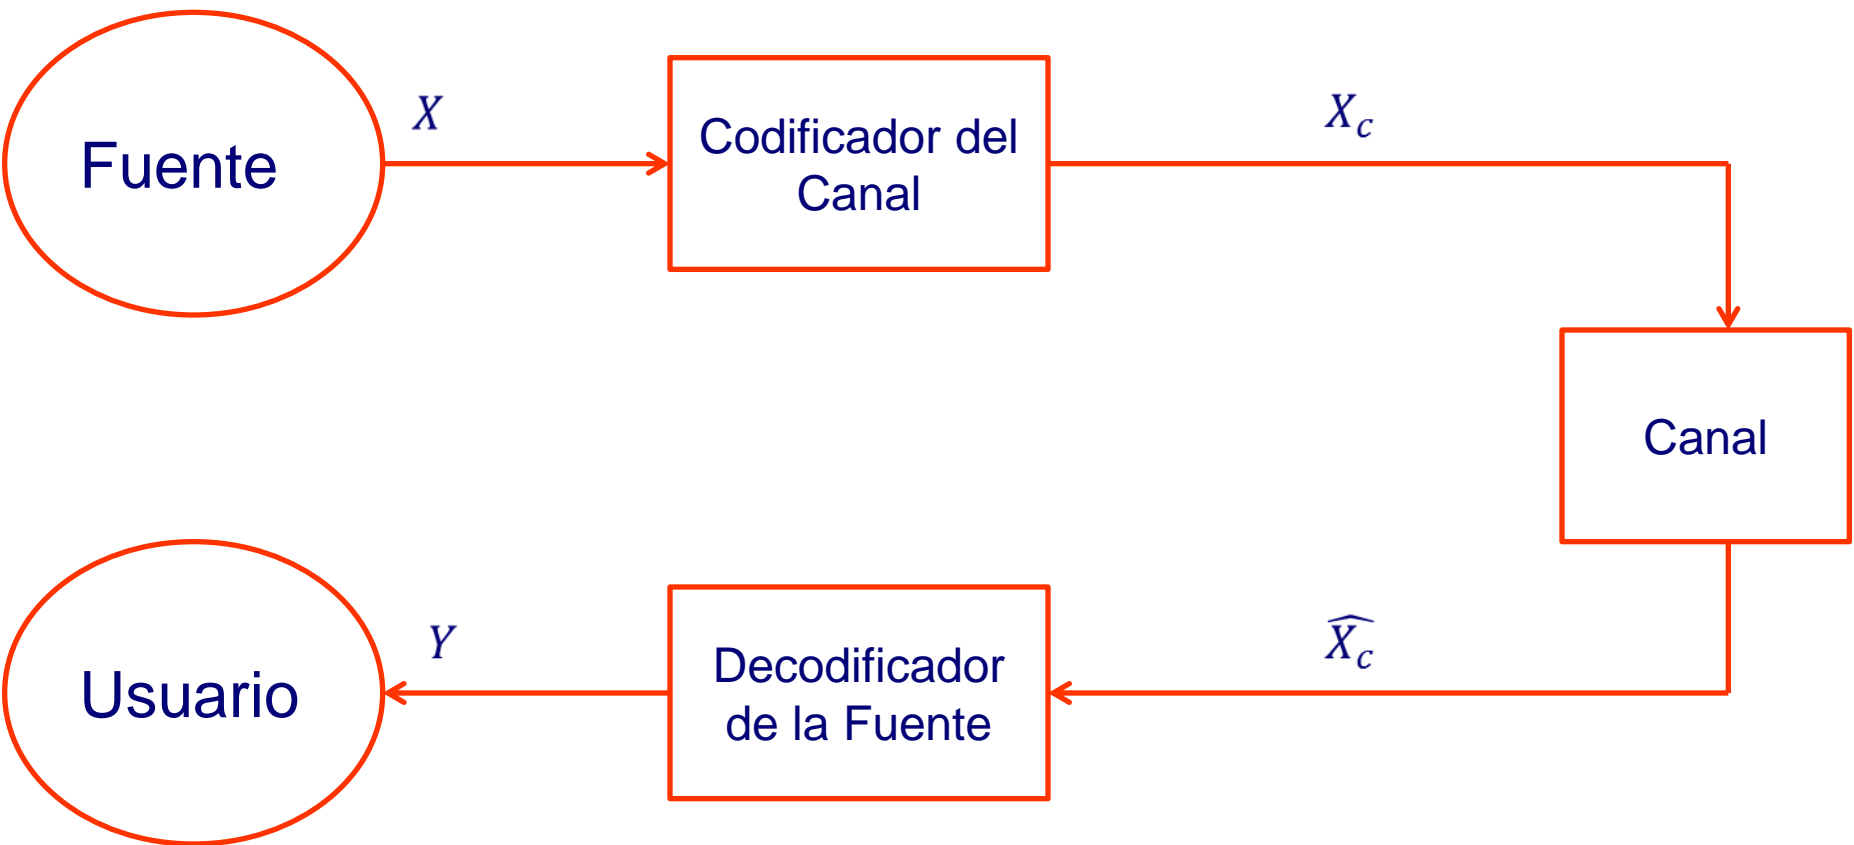
La teoría matemática subyacente al compromiso entre reducir la tasa y el aumento de la distorsión que esta reducción produce es **Teoría tasa/distorsión**, en inglés, **(Rate/Distortion Theory)** que estudiamos en este tema.

## II. Introducción.

En la codificación sin pérdida nunca tuvimos que preocuparnos por la diferencia entre la secuencia original y la reconstruida una vez comprimida dicha secuencia. Además, la entropía nos marcaba el límite inferior de nuestra tasa.

En la codificación con pérdida queremos disminuir lo más posible la **tasa** pero esto nos va a introducir una **distorsión**.

Los dos casos extremos son: enviamos cero información ( $\text{tasa}=0$ ) entonces la distorsión es muy grande o hacemos que la distorsión sea nula en cuyo caso la tasa es grande. El estudio de qué pasa entre estos dos extremos recibe el nombre de Teoría Tasa/Distorsión.



$\widehat{X}_c = X_c$  Canal sin ruido (supondremos que se cumple)

Si  $X_c$  reproduce fielmente  $X$  compresión sin pérdida,  
en caso contrario compresión con pérdida.

## Ejemplo II.1

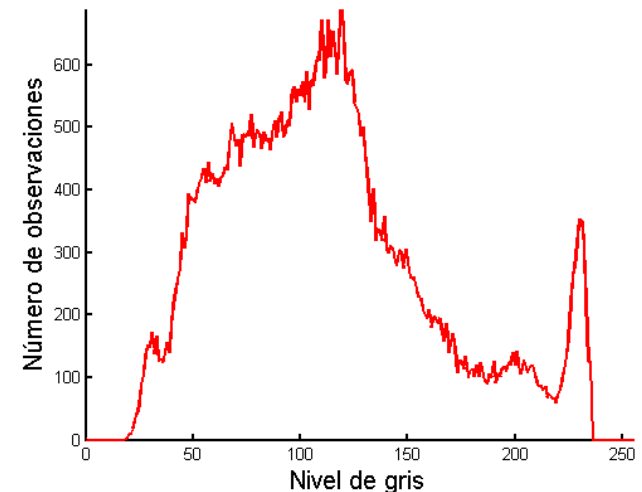
Consideremos la imagen de la derecha sin compresión, almacenada en 8 bits por píxel.

Sabemos que si consideramos los valores de los píxeles como realizaciones i.i.d., la entropía nos proporciona la menor tasa que podemos alcanzar sin distorsión.

$$H(p) = 7.4716 \text{ bits}$$

¿Y si tenemos menos bits o estamos dispuestos a soportar algo de distorsión?

Rafael Molina



```
Img=imread('goldhill.pgm');  
[histograma,bin]= hist(Img(:),[0:255]);  
prob=histograma/sum(histograma(:));  
positivos=prob(histograma>0.0);  
H=-sum(positivos.*log2(positivos))
```

Conceptos para codificación con pérdida

```
imshow(Img); figure;  
plot(bin,histograma,'-r','LineWidth',2),  
axis('tight');  
xlabel('Nivel de gris','FontSize',15);  
ylabel('Número de observaciones','FontSize',15);  
set(gca,'LineWidth',2,'box','off');
```

# III Criterios de distorsión

¿Cómo medimos la fidelidad de la fuente reconstruida a la original?.

Una forma natural de medir la fidelidad es examinar la diferencia entre el original y su reconstrucción. Sin embargo, existe un amplio debate sobre la utilización de otros criterios que después comentaremos.

Los criterios basados en diferencias utilizan normalmente la diferencia en valor absoluto o bien la diferencia al cuadrado.

Sean  $X$  la señal original e  $Y$  la reconstrucción:

## Preliminares

$x_n$  = señal original

$y_n$  = señal reconstruida

$1 \leq n \leq N$

Varianza de la señal

$$\sigma_x^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \text{Media}(X))^2$$

Error cuadrático medio

$$\sigma_d^2 = \frac{1}{N} \sum_{n=1}^N (x_n - y_n)^2$$

## Relación señal ruido

$$SNR_{RMS} = \frac{\sum_{n=1}^N (x_n - \text{Media}(X))^2}{\sum_{n=1}^N (x_n - y_n)^2} = \frac{\sigma_x^2}{\sigma_d^2}$$

Relación señal ruido en decibelios

$$SNR(dB) = 10 \log_{10} \frac{\sigma_x^2}{\sigma_d^2}$$

Pico de la relación señal ruido

$$PSNR(dB) = 10 \log_{10} \frac{x_{pico}^2}{\sigma_d^2}$$

$$x_{pico} = \max(X)$$

Conceptos para codificación con  
pérdida



Junto con la utilización de criterios matemáticos, podemos también usar como criterio la pregunta a un grupo de expertos (este sistema estará obviamente bastante sesgado) o intentar medir las discrepancias utilizando conocimiento sobre el sistema de percepción humano (OJO y OÍDO).

# Ejemplo III.1

Volvamos a nuestro ejemplo.



¿Cuál es el mejor codificador que puedo utilizar, si lo mejor significa: el menor error cuadrático medio entre la señal original y la reconstruida, y sólo dispongo de una tasa de bits por píxel pequeña?

Vamos a comprimir la imagen usando  $2^i$  valores distintos  $i=8,\dots,0$ . Vamos a calcular la distorsión entre la imagen original y la comprimida y la entropía de la imagen comprimida

```
close all; clear all;
Img=imread('goldhill.pgm');
distorsion=zeros(1,9);
rate=zeros(1,9);
H=zeros(1,9);
[M,N]=size(Img),
nele=M*N;
```

```
for i=0:8
```

```
    k=2^i;
    Imgq=uint8(floor(double(Img)/k));
    Imgreconst=uint8(k*(double(Imgq)+0.5));
    Error=double(Img)-double(Imgreconst);
    Error2=Error.*Error;
    distorsion(i+1)=sum(Error2(:))/nele;
    rate(i+1)=8-i;
    [histograma,bin]= hist(Imgq(:),[0:255]);
    prob=histograma/sum(histograma(:));
    positivos=prob(histograma>0.0);
    H(i+1)=-sum(positivos.*log2(positivos));
    figure;
    imshow (Imgreconst);
    title(sprintf('numero de niveles %d',256/k))
end
figure;
plot(distorsion,rate,'*'); hold on;
plot(distorsion,H,'+'); legend('Uniforme','Entropia')
xlabel('Distorsion','FontSize',15);
ylabel('Rate','FontSize',15);
set(gca,'LineWidth',2,'box','off');
```

Volveremos sobre él



numero de niveles 256



numero de niveles 32



numero de niveles 4



numero de niveles 128



numero de niveles 16



numero de niveles 2



numero de niveles 64




numero de niveles 8



numero de niveles 1



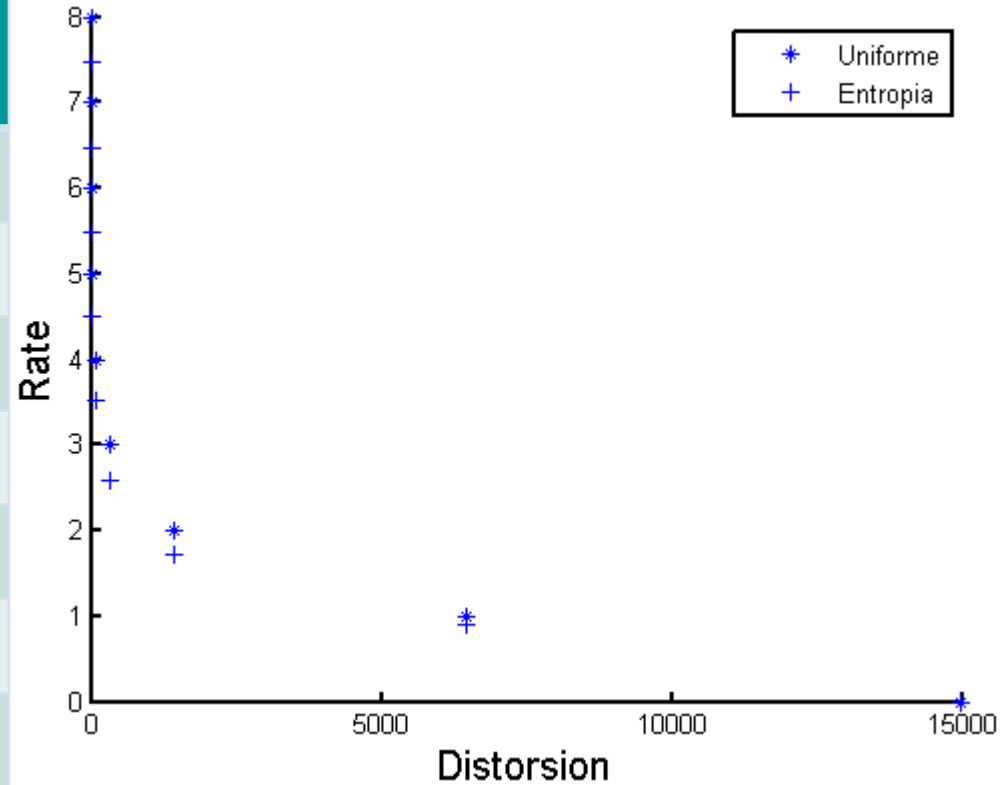
Distorsion	No. Bits (uniforme)	Entropía fuente cuantizada
1.0	8	7.47
.5	7	6.47
1.5	6	5.47
5.5	5	4.49
21.3	4	3.51
86.4	3	2.59
343.7	2	1.71
1319.0	1	0.89
2657.0	0	0.0



Observa, al ejecutar el programa de Matlab que la distorsión con 8 bits es 1 por haber introducido el 0.5 en Imgreconst

Si suprimimos el 0.5 obtenemos la siguiente tabla y gráfica


Distorsion	No. Bits (uniforme)	Entropía fuente cuantizada
0.0	8	7.47
1.0	7	6.47
4.0	6	5.47
18.0	5	4.49
76.0	4	3.51
320.0	3	2.59
1421.0	2	1.71
6471.0	1	0.89
15000.0	0	0.0



Dados los ejemplos anteriores cabe preguntarse:

- Dada una distorsión,  $D$ , ¿cual es el menor número de bits (la menor tasa) que tenemos que utilizar para que la distorsión sea  $D$ ?
- Dado un presupuesto (tasa) en bits,  $B$ , ¿Cuál es la menor distorsión que podemos obtener con un método de compresión?

Gráfico R/D típico



Estamos buscando un equivalente a la cota que nos proporciona la entropía cuando no hay distorsión para el caso en el que permitimos distorsión.

Tenemos que revisar, por tanto, la teoría de la información.

# IV. Teoría de la información revisitada

- Dada una medida de distorsión, para estudiar el compromiso entre tasa y distorsión en compresión con pérdida, nos gustaría definir explícitamente la tasa en función de la distorsión.
- Como veremos esto no es siempre posible (casi nunca) y tendremos que solucionar este problema. Antes de ello necesitamos algunos conceptos más sobre teoría de la información.



## Ejemplo 4.1

Un sistema de compresión con pérdida simple consiste en suprimir un cierto número de los bits menos significativos de la entrada.

Por ejemplo si tenemos imágenes monocromo de 8 bits, y sólo podemos ver 64 niveles de gris distintos, podemos suprimir los dos bits menos significativos. Con un ejemplo:

Nuestro alfabeto es  $\{0,1,2,\dots,15\}$ . El codificador codifica la fuente eliminando el bit menos significativo. La salida es entonces  $\{0,1,2,\dots,7\}$ . Nuestra estimación de la señal original se obtendrá añadiendo como bit menos significativo un cero. En otras palabras la reconstrucción será  $\{0,2,4,\dots,14\}$ .

## IV.1 Entropía Condicionada

Sea  $X$  una variable aleatoria que toma los valores del alfabeto  $X=\{x_0, x_1, \dots, x_{n-1}\}$  e  $Y$  la variable aleatoria de reconstrucción que toma valores en el alfabeto  $Y=\{y_0, y_1, \dots, y_{M-1}\}$ . Sabemos que la entropía de la fuente y de la reconstrucción valen respectivamente

$$H(X) = -\sum_{i=0}^{N-1} P(x_i) \log P(x_i)$$

$$H(Y) = -\sum_{j=0}^{M-1} P(y_j) \log P(y_j)$$

Supongamos que ahora fijamos un valor observado de  $Y$ , que lo notamos  $y_j$ , este valor produce la distribución condicionada  $P(x_0|y_j), P(x_1|y_j), \dots, P(x_{N-1}|y_j)$ . Su entropía es

$$H(X | Y = y_j) = - \sum_{i=0}^{N-1} P(x_i | y_j) \log P(x_i | y_j)$$

La media, con la distribución de  $Y$ , de estos valores recibe el nombre de entropía condicionada de  $X$  dado  $Y$ ,  $H(X|Y)$ , es decir

$$\begin{aligned} H(X | Y) &= \sum_{j=0}^{M-1} P(y_j) H(X | Y = y_j) \\ &= - \sum_{j=0}^{M-1} P(y_j) \sum_{i=0}^{N-1} P(x_i | y_j) \log P(x_i | y_j) \\ &= - \sum_{j=0}^{M-1} \sum_{i=0}^{N-1} P(y_j) P(x_i | y_j) \log P(x_i | y_j) \end{aligned}$$

Conceptos para codificación con  
pérdida

De igual forma podemos definir la entropía condicionada de Y a X,  $H(Y|X)$ ,

$$H(Y | X) = - \sum_{i=0}^{N-1} \sum_{j=0}^{M-1} P(x_i) P(y_j | x_i) \log P(y_j | x_i)$$

La entropía condicional  $H(X|Y)$  puede interpretarse como la cantidad de incertidumbre que queda en la variable X, dado que conocemos el valor que Y tomó.

Obviamente el conocimiento de Y debería reducir la incertidumbre sobre X. Puede probarse que

$$H(X | Y) \leq H(X)$$

## Ejemplo 4.2



Supongamos que tenemos una fuente con alfabeto  $X=\{0,1,\dots,15\}$  que son igualmente probables y que los codificamos haciendo cero el bit menos significativo. Tenemos

$$H(X) = \sum_{i=0}^{15} \frac{1}{16} \log 16 = 4 \text{ bits}$$

La variable codificada la notamos  $Y$  y tenemos  $Y=\{0,2,4,6,8,10,12,14\}$

$$P(Y = j) = P(X = j) + P(X = j+1) = \frac{1}{8}$$

y

$$H(Y) = 3 \text{ bits}$$

Además las probabilidades condicionadas valen

$$P(X = i | Y = j) = \begin{cases} 1/2 & \text{Si } i = j \text{ ó } i = j+1, j = 0, 2, \dots, 14 \\ 0 & \text{en el resto} \end{cases}$$

De donde

$$H(X | Y) = 1 \text{ bit}$$

Intuitivamente, de la observación de  $Y$  conocemos los tres bits más significativos de  $X$  y sólo nos queda por saber el restante.

## IV.2 Información Mutua Media

Dado  $y_j$  podemos construir la distribución de probabilidad  $P(x_k|y_j)$  y podemos medir la discrepancia entre  $P(x_k|y_j)$  y  $P(x_k)$ . Esto nos lleva a considerar la llamada información mutua que viene definida por

$$i(x_k; y_j) = \log \left( \frac{P(x_k | y_j)}{P(x_k)} \right)$$

comprueba que

$$\frac{P(x_k | y_j)}{P(x_k)} = \frac{P(y_j | x_k)}{P(y_j)}$$

¿ Qué ocurre si  $x$  e  $y$  son independientes?

Usando la información mutua, podemos definir la **información mutua media** mediante

$$I(X;Y) = \sum_{j=0}^{M-1} \sum_{k=0}^{N-1} P(y_j) P(x_k | y_j) \log \left( \frac{P(x_k | y_j)}{P(x_k)} \right)$$

Utilizando la entropía y la entropía condicionada, tendremos

$$\begin{aligned} I(X;Y) &= \sum_{j=0}^{M-1} \sum_{k=0}^{N-1} P(y_j) P(x_k | y_j) \log \left( \frac{P(x_k | y_j)}{P(x_k)} \right) \\ &= \sum_{j=0}^{M-1} \sum_{k=0}^{N-1} P(y_j) P(x_k | y_j) \log(P(x_k | y_j)) \\ &\quad - \sum_{j=0}^{M-1} \sum_{k=0}^{N-1} P(y_j) P(x_k | y_j) \log(P(x_k)) = H(X) - H(X | Y) \end{aligned}$$



Además como

$$\frac{P(x_k | y_j)}{P(x_k)} = \frac{P(y_j | x_k)}{P(y_j)}$$

se cumple

$$\begin{aligned} I(X;Y) &= \sum_{j=0}^{M-1} \sum_{k=0}^{N-1} P(y_j) P(x_k | y_j) \log \left( \frac{P(y_j | x_k)}{P(y_j)} \right) \\ &= H(Y) - H(Y | X) = I(Y; X) \end{aligned}$$

Ejemplo 7.4.3.

Para el ejemplo 7.4.2 tenemos  $H(X)=4$  bits y  $H(X|Y)=1$  bit.  
Por tanto  $I(X;Y)=I(Y;X)=3$  bits

Todos los conceptos estudiados en esta sección se extienden a variables continuas pero no los vamos a estudiar aquí.

# V. Teoría Razón/Distorsión

La teoría de la razón-distorsión estudia el compromiso entre distorsión y la tasa en esquemas de compresión con pérdida.

*La función  $R(D)$ , que recibe el nombre de función de tasa-distorsión, especifica la tasa más pequeña a la que la salida de una fuente puede ser codificada mientras se mantiene la distorsión menor o igual a  $D$ .*

Vamos a definir estos conceptos más formalmente. Tenemos que empezar definiendo lo que es la distorsión.

Supongamos que tenemos una fuente  $X$  con una distribución de probabilidad  $P(X)$ .

Si  $X$  ha tomado el valor  $x_i$  lo podemos codificar, tal vez con uno sólo, pero en general con un conjunto de valores  $\{y_j\}$ .

Si el valor de  $X$  es  $x_i$  y el de  $Y$  es  $y_j$  entonces habrá un error entre ellos que lo mediremos mediante  $d(x_i, y_j)$ .

¿Cómo se define entonces la distorsión?

$$D = \sum_i P(x_i) \left( \sum_j P(y_j | x_i) d(x_i, y_j) \right)$$

## Observa

- si tenemos una fuente  $X$  con una distribución de probabilidad  $P(X)$  y la medida de error  $d(x_i, y_j)$
- teniendo en cuenta la definición de distorsión lo que hará que ésta sea mayor o menor es la probabilidad condicionada que utilicemos.

Consideremos el ejemplo 6.4.2. y como medida de distorsión  $d(x_i, y_j) = (x_i - y_j)^2$ . Entonces la distorsión vale

$$D = \sum_{i=0,2,\dots,14} \frac{1}{16} \times 0 + \sum_{i=1,3,\dots,15} \frac{1}{16} \times 1 = \frac{1}{2}$$

Sea ahora  $D^*$  una distorsión (un valor de la distorsión) y consideremos el conjunto

$$\Gamma(D^*) = \left\{ P(Y | X) \mid \sum_i P(x_i) \left( \sum_j P(y_j | x_i) d(x_i, y_j) \right) \leq D^* \right\}$$


Shannon probó que la mínima tasa (número de bits) necesarios para codificar una fuente con una distorsión  $D^*$  viene dado por

$$R(D^*) = \min_{\Gamma(D^*)} I(X; Y)$$

y además demostró que **si describimos  $X$  con una tasa menor que  $R(D)$  nuestra distorsión nunca será menor que  $D$ .**

Veamos un gráfico R/D típico que ya conoces

## Gráfico R/D típico



# VI. Modelos para las fuentes

**Distribución Uniforme:** Si  $X \sim U[a, b]$  su función de densidad viene dada por

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{si } a \leq x \leq b \\ 0 & \text{en caso contrario} \end{cases}$$

que cumple  $E(X) = (b + a) / 2$ ,  $\text{var}(X) = (b - a)^2 / 12$

Si tenemos sólo dos valores para representar una realización de esta distribución ¿cómo lo harías?.

Llamemos  $Y$  a la representación. Sería razonable medir la distancia entre la realización  $X$  y su representación  $Y$  ¿cómo?

mediante  $(x-y)^2$

¿Y si tenemos 4 valores?. ¿Y si las realizaciones fuesen de las siguientes distribuciones?

**Distribución Normal o de Gauss:** Si  $X \sim N(\mu, \sigma)$  su función de densidad viene dada por

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(x - \mu)^2\right]$$

que cumple

$$E(X) = \mu, \quad \text{var}(X) = \sigma^2$$

**Distribución Laplaciana:** Son distribuciones más picudas. Su densidad tiene la forma


$$f_X(x) = \frac{1}{\sqrt{2\sigma^2}} \exp\left[-\frac{\sqrt{2}}{\sigma}|x|\right]$$

que cumple

$$E(X) = 0, \quad \text{var}(X) = \sigma^2$$



Gráfico de las funciones de densidad correspondientes a variables aleatorias con distribuciones uniforme, normal y de Laplace de media cero y varianza uno.



Además de los modelos descritos que suponen que las fuentes son independientes e idénticamente distribuidas, existen modelos que relacionan variables con las observadas con anterioridad.

Son los modelos autorregresivos y medias móviles y la mezcla de ambos autorregresivos-medias móviles que no estudiaremos aquí

# V Bibliografía

K. Sayood, "Introduction to Data Compression",  
Morgan and Kaufmann, 2012.

